

ÉCOLE CENTRALE CASABLANCA

SPRING 2026 — INTRODUCTION TO AI AND MACHINE LEARNING

When Machine Learning Fails

Diagnostic et réparation d'un mode d'échec
d'un modèle non-linéaire

Mini-projet – Investigation orientée recherche

Étudiantes : Samia TOUÏLE
Inass SEMMAR

Dataset : Online Shoppers Intention (UCI 468)

Modèle : Gradient Boosting Classifier

Mode d'échec : Overfitting and generalization gap (§5.2)

Encadrement : K. Zerhouni et R. Nassih (UTER MID@S)

14 mai 2026

Table des matières

1	Question de recherche et choix du dataset	1
1.1	Dataset et motivation	1
1.2	Choix du mode d'échec	1
2	Modèle de référence et symptôme observé	1
2.1	Modèle de référence	1
2.2	Symptôme observé : un écart train-validation préoccupant	2
3	Hypothèse causale et expérience contrôlée	3
3.1	Formulation de l'hypothèse	3
3.2	Contrôle bidirectionnel : la signature de la causalité	4
3.3	Identification de la source dominante du gap	5
4	Correction proposée et évaluation	6
4.1	Critère de succès défini <i>a priori</i>	6
4.2	Cinq candidats, cinq logiques	6
4.3	Résultats : la correction E' se distingue	7
4.4	Pourquoi E' est sélectionnée comme correction officielle	7
4.5	Validation : la learning curve corrigée	8
4.6	Test de significativité statistique	9
4.7	Mention rapide d'un second mode d'échec	9
5	Menaces à la validité	9
5.1	La non-significativité du F1 test n'est pas une preuve d'équivalence	9
5.2	Le caractère borderline de l'overfitting initial	10
5.3	Confondants potentiels dans la correction E'	10
5.4	Le choix de la métrique de gap	10
5.5	Absence de validation hors-distribution	10
5.6	Absence de fuite de données vérifiée	10
6	Conclusion et apprentissages	11
6.1	Ce que nous avons démontré	11
6.2	Ce que nous aurions fait différemment	11
6.3	Ce que ce projet nous a appris	11
A	Annexe : reproductibilité	12

1. Question de recherche et choix du dataset

1.1. Dataset et motivation

Nous travaillons sur le dataset **Online Shoppers Intention** (UCI 468), constitué de 12,330 sessions de navigation sur un site e-commerce, chacune décrite par 17 caractéristiques comportementales (pages vues, durées, taux de rebond) et contextuelles (mois, week-end, type de visiteur). La cible binaire **Revenue** indique si la session a conduit à un achat.

Ce dataset présente plusieurs propriétés qui en font un terrain d'investigation riche : un **déséquilibre de classe** marqué (15,5% d'achats), une **saisonnalité** forte (taux d'achat variant de 1,6% en février à 25,4% en novembre), et une asymétrie d'information entre les variables comportementales (riches) et contextuelles (parfois confondantes). Le sujet le cite explicitement (§4) comme un terrain propice à plusieurs modes d'échec : déséquilibre, dérive temporelle, shortcut learning.

1.2. Choix du mode d'échec

Notre démarche exploratoire (notebook `01_eda.ipynb`) a écarté l'hypothèse initiale d'un *shortcut learning sur le mois* : la feature **Month** n'apparaît qu'en deuxième position des importances (5,5%), très loin derrière **PageValues** (66,8%). En revanche, plusieurs symptômes convergeaient vers un **overfitting** : un F1 d'entraînement de 1,00 sur de petits jeux, un écart train/test de 0,13 sur le jeu complet, et une performance hétérogène entre mois (F1 variant de 0,48 à 0,77).

Le choix d'investiguer l'overfitting plutôt qu'un shortcut a été *guidé par les données*, pas par un *a priori*. Cette posture — laisser le diagnostic dicter la question de recherche, et non l'inverse — est cohérente avec la démarche scientifique demandée par le sujet (§1).

Question de recherche

*Le Gradient Boosting Classifier entraîné sur Online Shoppers présente-t-il un overfitting structurel (capacité excessive vis-à-vis de la taille du dataset), tel qu'une réduction **ciblée** de cette capacité — guidée par le diagnostic des courbes de validation — réduise l'écart train-validation d'au moins 30% sans dégrader significativement le F1 test ?*

Cette formulation satisfait les trois critères du §6.1 du sujet : elle est précise, falsifiable, et admet une réponse binaire après expériences.

2. Modèle de référence et symptôme observé

2.1. Modèle de référence

Nous utilisons un **GradientBoostingClassifier** (scikit-learn) avec les hyperparamètres par défaut, à l'exception de `n_estimators=200` et `max_depth=4` (configuration standard recommandée pour des données tabulaires modérément complexes). Le choix d'un modèle non-linéaire est imposé par la contrainte §3 du sujet ; le boosting d'arbres est privilégié à un MLP pour deux raisons : (i) les features sont hétérogènes (mélange de numériques continues et de catégorielles encodées), ce qui favorise les arbres, et (ii) le modèle conserve une interprétabilité minimale via les importances de

features, utile pour le diagnostic ultérieur.

Le *split* est aléatoire stratifié 80/20 sur la cible, avec `random_state=42`. La variance est mesurée par validation croisée à 5 plis.

Table 1 – Métriques de référence (modèle non régularisé).

Métrique	Valeur
Accuracy globale	0,8990
F1 (classe <i>purchase</i>)	0,6458
Recall (classe <i>purchase</i>)	0,5942
Precision (classe <i>purchase</i>)	0,7072
ROC-AUC	0,9265
F1 en validation croisée (5 plis)	0,6530 $\pm$ 0,0112

À première vue, ces chiffres sont *honorables* : 90% d’accuracy et une AUC supérieure à 0,92 suggèrent un modèle performant. Mais cette lecture est trompeuse : le déséquilibre 84/16 rend l’accuracy peu informative, et un *recall* de 0,59 signifie que **quatre acheteurs réels sur dix sont classés comme non-acheteurs**. C’est précisément le type de chiffre que masque une lecture superficielle des métriques globales.

2.2. Symptôme observé : un écart train-validation préoccupant

Le diagnostic se précise lorsque l’on confronte les performances train et test sur les mêmes données (Table 2). Le gap F1 atteint **0,128**, ce qui place le modèle dans une zone d’overfitting que nous qualifions de *modéré-confirmé* : suffisamment marqué pour justifier une investigation, suffisamment limite pour exiger une démonstration rigoureuse de la causalité (et non un constat).

Table 2 – Écart train/test du modèle de référence sur trois métriques.

Métrique	Train	Test	Écart
F1 (purchase)	0,7734	0,6458	+0,1276
Accuracy	0,9354	0,8990	+0,0364
ROC-AUC	0,9622	0,9265	+0,0358




Figure 1 — Courbes d'apprentissage du modèle de référence : F1 d'entraînement (noir) vs. F1 de validation (orange) en fonction de la taille du jeu d'entraînement.

La Figure 1 dévoile une dynamique qui enrichit considérablement le diagnostic. Sur un petit jeu ($n \approx 1,000$), le modèle **mémore parfaitement** ($F1 = 1,00$ sur le train) tandis que la validation plafonne à 0,62 — un écart de 0,38. À mesure que l'on augmente la taille du jeu, deux mouvements antagonistes se produisent : la performance d'entraînement **chute** (de 1,00 à 0,77), signe que le modèle ne parvient plus à mémoriser autant d'exemples, tandis que la validation **progresses** (0,62 à 0,65). L'écart final reste de 0,11 environ.

Cette dynamique nous dit deux choses importantes. D'abord, l'overfitting est bien **une propriété de capacité** : le modèle a la possibilité structurelle de mémoriser, et l'exerce dès qu'on lui donne peu de données. Ensuite, plus subtilement, l'overfitting n'est pas catastrophique : les courbes ne se sont pas *stabilisées*. Avec un dataset cinq fois plus grand, le gap pourrait probablement se résorber naturellement. Notre investigation porte donc sur un cas *borderline*, ce qui rendra le succès de la correction d'autant plus exigeant à démontrer.

3. Hypothèse causale et expérience contrôlée

3.1. Formulation de l'hypothèse

Hypothèse H1 (falsifiable)

La **capacité du modèle** — mesurée par la profondeur des arbres, leur nombre, et la granularité des feuilles — est la cause principale du gap train-validation observé.

Prédiction falsifiable : augmenter la capacité doit *aggraver* le gap, la réduire doit le *diminuer*. Si le gap reste constant ou évolue de manière non monotone, H1 est falsifiée et l'overfitting doit

être attribué à une autre cause (par exemple, un bruit étiqueté ou une fuite d'information).

Cette hypothèse est délibérément formulée de manière à pouvoir être réfutée par une seule expérience bien construite. C'est ce qui la distingue d'une simple *conjecture* : nous identifions à l'avance le résultat qui invaliderait notre raisonnement.

3.2. Contrôle bidirectionnel : la signature de la causalité

Le sujet exige (§6.3) un « *proper control : a setting in which the cause is absent* ». La manière la plus pauvre de répondre à cette exigence serait de comparer simplement le modèle de référence à un modèle régularisé. Mais cela ne mesure qu'une direction de la causalité : on observerait une baisse de gap après régularisation sans pouvoir exclure que d'autres facteurs (changement de variance, effet de seed, etc.) en soient responsables.

Nous adoptons donc une approche plus rigoureuse : un **contrôle bidirectionnel**, où la capacité est variée dans les **deux sens** autour de la référence (Tableau 3).

Table 3 – Contrôle bidirectionnel : effet de la capacité du modèle sur l'écart train-validation.

Condition	max_depth / leaf / n_est	Gap F1	Train F1
<i>Cause absente</i> (low)	2 / 50 / 100	+0,0387	0,666
Référence	4 / 1 / 200	+0,1276	0,773
<i>Cause amplifiée</i> (high)	10 / 1 / 500	+0,3565	1,000




Figure 2 – Visualisation du contrôle bidirectionnel : le gap train-validation varie de manière strictement monotone avec la capacité du modèle.

Résultat

Monotonie observée : low (+0,039) < référence (+0,128) < high (+0,357).

Le gap est multiplié par ~ 9 entre les deux configurations extrêmes. La relation **capacité** $\rightarrow$ **gap** est strictement croissante, ce qui constitue la signature attendue d'une causalité (et non

d'un simple effet de modèle ou d'un artefact). **H1 est confirmée.**

Notons un détail méthodologiquement important : à capacité maximale (condition *high*), le F1 d'entraînement atteint exactement 1,000. Le modèle mémorise parfaitement la totalité du jeu d'entraînement (9,864 exemples), ce qui n'arrive avec aucune autre configuration. C'est l'expression la plus pure de l'overfitting — et le fait qu'on puisse le *provoquer à volonté* en augmentant la capacité prouve que cette dernière est bien le levier causal.

3.3. Identification de la source dominante du gap

Avoir démontré que la capacité cause l'overfitting ne suffit pas : il faut identifier **lequel des trois hyperparamètres** (`max_depth`, `n_estimators`, `min_samples_leaf`) contribue le plus, afin de cibler la correction. Les courbes de validation (Figure 3) répondent à cette question.




Figure 3 — Courbes de validation : effet de chaque hyperparamètre, isolé, sur l'écart train-validation.

Table 4 — Synthèse des effets de chaque hyperparamètre sur le gap F1.

Hyperparamètre	Plage testée	Gap min	Gap max
<code>max_depth</code>	2 – 10	0,027	0,350
<code>n_estimators</code>	50 – 500	0,052	0,209
<code>min_samples_leaf</code>	1 – 100	0,061	0,115

Trois observations structurent la suite de l'analyse :

(1) La profondeur est le principal vecteur. Le ratio gap-max / gap-min vaut ~ 13 pour `max_depth`, contre ~ 4 pour `n_estimators` et ~ 2 pour `min_samples_leaf`. Réduire la profondeur est donc l'intervention au plus fort effet attendu.

(2) Le nombre d'arbres est secondaire. L'effet existe mais reste modéré ; il interagira plutôt avec `learning_rate` dans la correction finale.

(3) La granularité des feuilles est un régularisateur *passif*. Contrairement aux deux autres, `min_samples_leaf` ne crée pas le gap : c'est en l'*augmentant* qu'on le réduit. Il agit comme une contrainte structurelle qui empêche les feuilles d'apprendre du bruit local.

Cette analyse fournit le **plan de la correction** : attaquer prioritairement la profondeur, ajouter une contrainte sur les feuilles, et compléter par des mécanismes secondaires (learning rate, sous-échantillonnage).

4. Correction proposée et évaluation

4.1. Critère de succès défini *a priori*

Une difficulté méthodologique récurrente, soulignée par le sujet (§6.4), est qu'*une correction qui améliore le F1 test sans attaquer la cause est une rationalisation a posteriori, pas un résultat scientifique*. Pour nous prémunir contre cela, nous définissons le critère de succès **avant** de regarder les résultats :

Critère de succès *a priori*

Une correction est **validée** si et seulement si elle satisfait les deux conditions suivantes :

- **(C1)** Réduction du gap d'au moins **30%** : nouveau gap $\leq 0,0893$.
Justification : cible la cause (l'overfitting). En-deçà de 30%, l'effet est trop modeste pour exclure la variance des seeds.
- **(C2)** Maintien du F1 test : nouveau F1 $\geq 0,6346$ (référence $- 1\sigma_{CV}$).
Justification : évite le sous-fitting déguisé. Une correction qui ferme le gap en faisant chuter *aussi* la performance test n'a pas attaqué la cause : elle a simplement détruit le modèle.

Une correction qui passe (C1) mais échoue (C2) est rejetée comme sous-fitting. Une correction qui passe (C2) mais échoue (C1) est rejetée comme symptôme masqué.

4.2. Cinq candidats, cinq logiques

Nous évaluons cinq corrections, chacune incarnant une logique d'intervention distincte (Tableau 5). Chaque modèle est entraîné sur **5 seeds différentes** pour mesurer la variance et permettre un test de significativité statistique ultérieur.

Table 5 – Candidats à la correction : logiques d'intervention.

Modèle	Levier	Logique
A – Référence	aucun	baseline overfittée
B – depth=2	profondeur seule	cible le levier principal identifié en §3.3
C – leaf=50	granularité seule	test du régularisateur passif
D – early stopping	durée d'entraînement	mécanisme indépendant des deux précédents
E – combinaison	5 leviers	combinaison <i>naïve</i> multi-axes (sans calibrage fin)
E' – guidée	5 leviers	combinaison <i>calibrée</i> : chaque valeur découle d'une observation de la §3.3

Le contraste entre E et E' mérite d'être explicité. La correction E utilise des valeurs « par défaut

raisonnables » (depth=3, leaf=20, lr=0,03, subsample=0,7) : c'est une intervention multi-axes mais peu informée. La correction E' utilise les *extrêmes calibrés* des courbes de validation : depth=2 (où le gap était minimal à 0,027), leaf=100 (régularisation maximale testée), lr=0,03 (ralentit la mémorisation au sein de chaque arbre), subsample=0,7 (bruit stochastique), et early stopping. La différence n'est pas dans la quantité de leviers utilisés, mais dans la **traçabilité** de chaque choix à une observation préalable.

4.3. Résultats : la correction E' se distingue

Table 6 — Évaluation des cinq corrections (moyenne $\pm$ écart-type sur 5 seeds).

Modèle	Train F1	Test F1	Gap	AUC	C1	C2
A – Référence	0,7744	0,6509 $\pm$ 0,0082	+0,1235	0,9268	—	—
B – depth=2	0,6806	0,6401 $\pm$ 0,0010	+0,0405	0,9243	✓	✓
C – leaf=50	0,7430	0,6536 $\pm$ 0,0012	+0,0894	0,9277	×	✓
D – early stop	0,7310	0,6496 $\pm$ 0,0046	+0,0814	0,9271	✓	✓
E – combiné	0,7058	0,6364 $\pm$ 0,0051	+0,0694	0,9255	✓	✓
E' – guidée	0,6760	0,6414 $\pm$ 0,0079	+0,0346	0,9246	✓	✓




Figure 4 — Comparaison des cinq corrections : F1 test (haut), gap (milieu), AUC (bas).

Quatre corrections sur cinq passent le critère a priori. Seule C (`min_samples_leaf=50`) est rejetée : son gap (0,0894) dépasse de 0,0001 le seuil de 0,0893. Une rationalisation a posteriori aurait été tentée ici — arrondir, étendre le seuil, etc. — mais nous nous abstenons : le critère a été figé avant l'expérience, et nous le respectons. C'est précisément le bénéfice de la définition a priori.

4.4. Pourquoi E' est sélectionnée comme correction officielle

Parmi les quatre corrections validées, laquelle retenir comme correction « officielle » du projet ? Cette question n'est pas anodine : un choix mal justifié trahit l'hypothèse H1.

Notre logique de sélection est la suivante : si H1 affirme que l'overfitting est la cause, alors la meilleure correction est celle qui **attaque le plus la cause**, c'est-à-dire celle qui **minimise**

le **gap** parmi les modèles validés. Le F1 test n'est qu'un *filtre de sécurité* (C2), pas un critère d'optimisation. Sélectionner sur le F1 test reviendrait à optimiser le symptôme, exactement ce que le sujet (§10) appelle un fix trivial.

Correction officielle retenue : E'

E' – Régularisation guidée par diagnostic

Gap réduit : 0,1276 → 0,0346, soit une **réduction de 72,9%**.

F1 test : $0,6414 \pm 0,0079$ (référence : 0,6458, écart non significatif).

Le choix d'E' n'est pas *le plus performant* (C a un meilleur F1 test, B a un gap quasi équivalent) mais *le mieux justifié* : chacun de ses hyperparamètres dérive d'une observation explicite des courbes de validation. C'est ce que le sujet appelle « non-trivial » au §10 : non pas un fix sophistiqué *en soi*, mais un fix dont chaque ingrédient est *traçable* à un diagnostic.

4.5. Validation : la learning curve corrigée




Figure 5 – Comparaison des learning curves référence (A) et corrigée (E').

La Figure 5 apporte la validation *visuelle* de la correction. Là où le modèle de référence mémorisait parfaitement les petits jeux d'entraînement, le modèle E' converge vers un F1 d'entraînement modéré ($\sim 0,68$) qui est *quasiment confondu* avec la courbe de validation. Le gap final passe de 0,123 à 0,035, soit une réduction de **72%**¹.

1. La légère différence entre les 72,9% du Tableau 6 et les 72,0% de cette figure provient des tailles d'échantillon utilisées pour chaque mesure (jeu complet vs. moyenne sur les tailles de la learning curve). L'écart est inférieur à 1% et confirme la robustesse du résultat.

Plus important encore : l'écart-type entre les seeds reste de 0,008 (similaire à celui de la référence), ce qui exclut que le résultat soit un artefact de seed favorable.

4.6. Test de significativité statistique

Pour répondre à l'exigence du §7 (« *could the observed gain be explained by random variability across seeds ?* »), nous comparons les distributions de F1 test entre A et E' par un *t-test* bilatéral apparié sur les 5 seeds (Tableau 7).

Table 7 – Test de significativité : E' vs. référence A.

Quantité	Valeur
Δ F1 test (E' – A)	–0,0095
Δ Gap (E' – A)	–0,0889
Statistique <i>t</i>	1,672
<i>p</i> -value	0,133

Avec $p = 0,13 > 0,05$, nous **ne pouvons pas rejeter** l'hypothèse nulle d'égalité des F1 test. Autrement dit, la baisse apparente de 0,0095 sur le F1 test n'est pas distinguable du bruit inter-seed. Combinée à la baisse massive du gap (–0,0889), cette absence de différence significative sur le test est exactement le résultat *attendu* sous H1 : on a attaqué la cause (capacité) sans toucher au signal informatif (généralisation).

4.7. Mention rapide d'un second mode d'échec

Au-delà de l'overfitting, le dataset présente un second mode d'échec dont les symptômes sont visibles dans nos résultats : le **déséquilibre de classe** (§5.1 du sujet). Le *recall* de la classe minoritaire (0,59) signale que 40% des acheteurs réels sont classés comme non-acheteurs. Plusieurs corrections seraient envisageables : `class_weight='balanced'` (modifie la fonction de coût), SMOTE (équilibre artificiellement les données), ou un ajustement du seuil de décision. Une investigation rigoureuse exigerait un cadre expérimental analogue à celui développé ici — formulation d'hypothèse, contrôle, critère a priori — que nous laissons en perspective pour ne pas diluer l'argument principal sur l'overfitting.

5. Menaces à la validité

Cette section discute, conformément au §7 du sujet, les raisons pour lesquelles nos conclusions pourraient être incorrectes. Nous adoptons délibérément une posture critique : reconnaître les limites d'une analyse renforce sa crédibilité davantage que de la défendre à tout prix.

5.1. La non-significativité du F1 test n'est pas une preuve d'équivalence

Notre *p*-value de 0,13 indique que la baisse de F1 (–0,0095) n'est pas *détectablement différente* de zéro avec $n = 5$ seeds. Mais cette absence de détection **n'est pas équivalente à une absence d'effet**. Un échantillon plus grand ($n = 20$ seeds par exemple) permettrait de mieux trancher :

soit confirmer que la différence est nulle, soit révéler une dégradation modeste mais réelle. Notre conclusion « E' ne dégrade pas significativement le F1 » doit donc être lue avec cette précaution.

5.2. Le caractère borderline de l'overfitting initial

Le gap initial de 0,128 est dans une zone modérée. Sur un dataset plus petit (par exemple 1,000 sessions au lieu de 12,330), ou avec un modèle plus complexe (XGBoost à 1,000 arbres), l'effet observé serait probablement plus marqué et plus facile à corriger spectaculairement. Inversement, sur un dataset plus grand, l'overfitting se résorberait peut-être de lui-même, rendant la correction inutile. **Nos conclusions ne se transposent donc pas mécaniquement à d'autres configurations dataset/modèle.**

5.3. Confondants potentiels dans la correction E'

La correction E' modifie cinq hyperparamètres simultanément. Bien que chaque choix soit individuellement justifié par la §3.3, on ne peut pas garantir qu'un sous-ensemble plus petit n'aurait pas suffi. La correction B (`max_depth=2` seul) atteint déjà un gap de 0,0405 contre 0,0346 pour E' : la différence (0,006) est faible, et il est plausible que la quasi-totalité de l'effet de E' provienne de la seule réduction de profondeur, les autres ingrédients n'ajoutant qu'un effet marginal. Cette ambiguïté affecte notre démonstration de la *non-trivialité* d' E' : si B suffit, alors E' est sur-conçue.

5.4. Le choix de la métrique de gap

Nous avons défini le gap comme `train_F1 - test_F1`. D'autres définitions sont possibles : différence de log-loss, différence d'AUC, ou écart de calibration. Sur notre dataset, le gap d'AUC est de 0,036 (très faible), ce qui peut surprendre face à un gap F1 de 0,128. La raison est que F1 dépend du seuil de décision (0,5 par défaut) tandis que l'AUC en est indépendant. **Une partie de ce que nous appelons « overfitting » pourrait donc être un problème de calibration du seuil, distinct d'une véritable mémorisation.** Cette nuance mériterait une investigation séparée.

5.5. Absence de validation hors-distribution

Toutes nos évaluations sont sur un split aléatoire de la même distribution. Or, l'utilité finale d'une correction de l'overfitting est de mieux *généraliser*, ce qui ne se vérifie que sur des données *hors-distribution* (autres mois, autre période, autre site e-commerce). Nous n'avons pas réalisé cette évaluation par manque de données externes comparables. C'est probablement la limite la plus importante de notre travail : une réduction du gap sur un même split aléatoire ne garantit pas une meilleure performance déployée.

5.6. Absence de fuite de données vérifiée

Le split est stratifié sur la cible mais pas sur le mois. Il est possible que certaines sessions du test set proviennent d'un mois sur-représenté dans le train, créant une forme indirecte de fuite. Une évaluation rigoureuse exigerait un split temporel (train sur jan-sep, test sur oct-déc) que nous n'avons pas mené ici pour rester aligné avec notre question de recherche centrée sur la capacité.

6. Conclusion et apprentissages

6.1. Ce que nous avons démontré

Notre investigation aboutit à trois conclusions précises, hiérarchisées par force de preuve :

(1) Démontré. La capacité du modèle est la cause causale de l'écart train-validation sur ce dataset. Le contrôle bidirectionnel (gap multiplié par neuf entre low et high capacity) constitue la preuve la plus forte, car il vérifie les *deux* directions de la prédiction de H1.

(2) Démontré conditionnellement. Une correction guidée par diagnostic (E') réduit le gap de 72,9% *sans dégrader significativement* le F1 test. Le « sans dégrader » est conditionnel à l'absence de détection avec $n = 5$ seeds ; il pourrait être contredit avec un échantillon plus grand.

(3) Suggéré, non démontré. La traçabilité du choix des hyperparamètres aux observations des courbes de validation rend la correction « non triviale » au sens du sujet. Mais comme noté en §5.3, il est possible qu'une correction beaucoup plus simple (B seule) capture l'essentiel de l'effet, auquel cas la sophistication d' E' serait sur-conçue.

6.2. Ce que nous aurions fait différemment

Avec le recul, plusieurs choix mériteraient d'être révisés.

Une expérience d'ablation séquentielle. Pour démontrer la non-trivialité d' E' , nous aurions dû tester E' *moins* chaque ingrédient individuel (E' sans subsample, E' sans early stopping, etc.). Cela aurait permis de quantifier la contribution marginale de chaque levier et d'identifier la combinaison minimale efficace. C'est l'analyse de *Shapley values* appliquée aux hyperparamètres : nous l'avons reportée par contrainte de temps.

Un test temporel out-of-distribution. Comme mentionné en §5.5, l'absence d'évaluation hors-distribution est notre limite principale. Un split *train sur jan-sep / test sur oct-déc* aurait converti la question « le modèle généralise-t-il mieux ? » en une question opérationnelle directe. Le sujet le suggère d'ailleurs implicitement en mentionnant la dérive temporelle dans la description du dataset (§4).

Plus de seeds. La variance inter-seed sur 5 itérations est élevée (écart-type $\sim 0,008$). Doubler ou tripler le nombre de seeds aurait permis de réduire l'incertitude statistique sans coût méthodologique. C'est un compromis temps/rigueur que nous avons probablement réglé du mauvais côté.

6.3. Ce que ce projet nous a appris

Au-delà du résultat technique, trois apprentissages méthodologiques se dégagent.

Le diagnostic précède la correction. Notre première intuition — un *shortcut learning* sur la variable `Month` — était plausible et bien défendue dans la littérature pour ce type de dataset. Les données l'ont écartée. Sans une exploration honnête des features importances et des perfs par mois, nous aurions perdu trois jours à régulariser une variable qui n'était pas le problème. *Investiguer le*

symptôme avant de formuler l'hypothèse n'est pas un détour : c'est l'étape qui économise le plus de temps.

Le critère a priori protège contre soi-même. Définir « la correction est validée si $\text{gap} \leq 0,0893$ et $F1 \geq 0,6346$ » *avant* l'expérience peut sembler bureaucratique. C'est précisément ce qui nous a empêchées de rationaliser le résultat de la correction C (gap 0,0894, à 10^{-4} du seuil). En sciences appliquées, la tentation d'ajuster les seuils a posteriori est constante ; le seul rempart est de figer le critère avant. Nous mesurons mieux, désormais, pourquoi la pré-enregistrement des expériences gagne du terrain dans les domaines empiriques.

Une réduction de gap n'est pas une amélioration garantie. Notre conclusion principale est paradoxale : la « meilleure » correction (E') a un F1 test *plus bas* que la référence. Un correcteur pressé pourrait conclure que la correction « ne marche pas ». Mais le gap réduit signifie une moindre dépendance aux patterns spécifiques du train, ce qui devrait se traduire par une meilleure robustesse face à un futur changement de distribution — changement que nous n'avons pas pu vérifier ici. *Le gain est dans la garantie de généralisation, pas dans le chiffre du test.* Cette distinction — entre performance immédiate et fiabilité — est sans doute le concept le plus important que ce projet nous laisse pour l'avenir.

A. Annexe : reproductibilité

Code. L'intégralité du code :

- `01_eda.ipynb` : exploration, modèle de référence, learning curve, importances.
- `02_experiment.ipynb` : symptôme quantifié, contrôle bidirectionnel, courbes de validation, 5 corrections, validation.
- `data/online_shoppers_intention.csv` : dataset source.
- `report/` : figures et métriques JSON.

Versions. Python 3.12, scikit-learn 1.4, pandas 2.2, matplotlib 3.8.

Seeds. `RANDOM_STATE=42` pour le seed principal. Variance mesurée sur 5 seeds : 42, 43, 44, 45, 46.

Reproductibilité. Les notebooks 01 et 02 sont exécutables *indépendamment* (notebook 02 recharge le CSV et refait le preprocessing). Un **Restart & Run All** sur kernel vierge reproduit l'intégralité des résultats du rapport.